

Simulation et Évaluation de Stratégies de Paris Sportifs

Lawin DIRIK Fantin VICO Clément BOLIFRAUD

Université de Caen Normandie

3 juin 2026

- 1 Introduction et Problématique
- 2 Acquisition des Données
- 3 Méthodologie et Stratégies
- 4 Résultats et Analyse
- 5 Architecture et Interface
- 6 Répartition du Travail
- 7 Conclusion

Le Marché

- Industrie colossale (Milliards d'euros).
- Avantage mathématique du bookmaker : la **Marge** (*Overround*).

Problématique

Est-il possible de développer des stratégies algorithmiques (heuristiques ou IA) capables de surmonter la marge du bookmaker et de générer un profit sur le long terme ?

Objectifs :

- Constituer un Dataset fiable (Premier League).
- Implémenter des stratégies (Naïves, Risque, ML, NLP).
- Simuler un portefeuille (Backtesting 100€).

La qualité des prédictions dépend de la richesse des données.

- **Données Historiques (CSV) :**

- Source : *football-data.co.uk*
- Volume : 4 saisons (2020-2024), >1500 matchs.
- Contenu : Résultats (FTR) + Cotes de fermeture.

- **Temps Réel (API) :**

- The Odds API : Cotes en direct (Bet365, Pinnacle).
- NewsAPI : Contexte médiatique (5 derniers articles).

Traitement (Pipeline)

Nettoyage, conversion temporelle et *Label Encoding* pour le Machine Learning.

1. Approches Heuristiques (Statiques)

Règles fixes pour établir un *Benchmark*.

Stratégies Naïves

- Toujours Domicile (Avantage terrain).
- Toujours Extérieur.
- Toujours Nul.

Basées sur le Risque

- **Low-Risk** : Parier sur la cote min (Favori).
- **High-Risk** : Parier sur la cote max (Outsider).

Stratégie "Custom" (Optimisée)

Hypothèse : Les bookmakers sous-estiment les visiteurs "moyens".

Parier Extérieur SI $3.0 \leq \text{Cote} < 4.0$

2. Approche Adaptative : Random Forest

Modélisation mathématique via `scikit-learn`.

- **Features (X)** : Équipes (encodées) + Cotes (C_H, C_D, C_A).
- **Algorithme : Random Forest Classifier.**
 - Vote majoritaire de plusieurs arbres de décision.
 - Réduit le sur-apprentissage (Overfitting).

Protocole Rigoureux : Split Temporel

Pas de `shuffle=True` !

- **Train** : 80% (Passé).
- **Test** : 20% (Futur simulé).

3. Le Seuil de Confiance (S_c)

Le Formalisme de `predict_proba`

Chaque arbre renvoie la proportion empirique de sa feuille. La forêt calcule la moyenne continue de ces probabilités :

$$P(Y = k \mid x) = \frac{1}{N} \sum_{i=1}^N P_i(Y = k \mid x)$$

L'indice de confiance $\mathcal{C}(x)$ extrait la probabilité maximale de l'issue choisie.

Le Filtre d'Abstention

Le capital n'est engagé que si l'IA surmonte son seuil critique de certitude :

$$\text{Décision} = \begin{cases} \text{Parier sur la classe } \hat{y} & \text{si } \mathcal{C}(x) \geq S_c \\ \text{Abstention (Aucun trade)} & \text{si } \mathcal{C}(x) < S_c \end{cases}$$

4. Exploration de l'Espace : Le Grid Search

Optimisation Combinatoire

Recherche automatisée de la meilleure structure de paramètres via `grid_search_RF.py`.

- Espace exploré : $\Omega = N_{\text{estimators}} \times \text{Max}_{\text{depth}} \times S_c$.
- Génération automatique d'un rapport structuré au format CSV.

5. Gestion Dynamique du Capital : Le Critère de Kelly

Le Principe

Plutôt que de miser une somme fixe (*flat betting*), l'algorithme ajuste la mise en fonction de l'avantage mathématique (la *Value*) calculé par le Random Forest.

$$f^* = p - \frac{q}{b}$$

- p = Probabilité de victoire estimée par l'IA.
- q = Probabilité de perdre le pari
- b = Profit net offert par le bookmaker (Cote - 1)

Le "Fractional Kelly"

Le Kelly pur est trop volatil. Nous avons implémenté un multiplicateur fractionnaire combiné à un plafond de sécurité (mise maximale fixée à 15% du capital courant) pour lisser le risque.

Limite de l'approche initiale

L'analyse restreinte aux **titres d'articles** captait trop de "bruit" et manquait de nuance pour générer des prédictions fiables.

Nouvelle Approche : Scraping Profond (newspaper3k)

Extraction et analyse du **corps complet** des articles de presse pour capter la dynamique médiatique.

- **Ciblage de qualité** : Requête via NewsAPI et exclusion automatique des domaines non pertinents (msn, yahoo, pages de cookies).
- **Volume** : L'algorithme s'arrête lorsqu'il a validé le scraping intégral de **8 articles fiables** par équipe.

Problème : Un même article peut parler des deux équipes. Comment ne pas fausser le score ?

Le Pipeline de Filtrage Contextuel

- ➊ **Découpage** : Le corps du texte est scindé en phrases distinctes.
 - ➋ **Isolement** : L'algorithme ne conserve *que* les phrases contenant explicitement le mot-clé de l'équipe (ex : "Chelsea").
 - ➌ **Agrégation** : Concaténation de ces phrases en un seul bloc texte pertinent.
 - ➍ **Scoring** : TextBlob évalue la polarité de ce bloc pour attribuer un score de -1 à $+1$.
- **Bénéfice** : Suppression du bruit ambiant.
 - **Décision** : Un *Value Bet* est déclenché si le score moyen des 8 articles dépasse **0.20** (dynamique positive stable).

6. Value Betting (Anomalie de Forme)

Le Concept

Exploiter les inefficacités du marché en ciblant des rencontres où la dynamique récente des équipes (calculée sur les 5 derniers matchs) n'est pas correctement reflétée par les cotes.

Paramètres d'optimisation du Backtest :

- **Seuil d'Écart de Forme** : Différence de points acquis (sur 15 possibles) entre les deux équipes avant le coup d'envoi.
- **Cote Minimale acceptée** : Filtre mathématique pour garantir une espérance de gain suffisante face à la marge du bookmaker.

Hypothèse de marché

Une équipe présentant une dynamique significativement meilleure que son adversaire, mais conservant une cote élevée, constitue un potentiel *Value Bet*.

7. Application du modèle : Stratégie de Prédiction

Ingestion & Normalisation (*The Odds API*)

- **Flux Live JSON** : Extraction des cotes en temps réel et des probabilités implicites du marché.
- **Normalisation** : On normalise les équipes via un dictionnaire de correspondance avant de les insérer dans le modèle entraîné.

Moteur de Poisson

Simulation du score exact
Calcul de l'espérance de buts (λ) :

$$\lambda_{dom} = Att_{dom} \times Def_{ext} \times Moy_{ligue}$$

- Distribution de probabilités.
- Génération des *Fair Odds* (cotes réelles).

$$P(k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Inférence Random Forest

Machine Learning

Filtrage de rentabilité

- Entrées : Vecteurs normalisés.
- Analyse des écarts de cotes.
- Verdict : **BET / SKIP**.

 **Cible : EV $\geq$ 1.05**

- **Logique de Décision** : On applique la technique du Random Forest à notre stratégie gagnante *Custom* afin d'accroître nos chances de gain.

Criblage des Opportunités (Value Betting)

- **Plage de Cotes** : Sélection exclusive entre **3.0 et 4.0** (Cibles à haute valeur).
- **Calcul de l'EV** : $ExpectedValue = Probabilite \times Cote$.
- **Seuil de Rentabilité** : Activation du signal de pari uniquement si **EV ≥ 1.05** (Marge de sécurité de 5%).

Résultats du Modèle

- Le système émet une prédiction finale (*Bet* ou *Non rentable*).
- **Indice de fiabilité** : Affichage de l'EV précis pour quantifier l'avantage statistique.

Comparaison des Performances (ROI)

Stratégie	Paris	Win Rate	ROI
Toujours Domicile	617	38.74%	-16.12%
Low-Risk (Favori)	1507	56.47%	-1.11%
Machine Learning (RF)	304	57.89%	0.16%
Custom (3.0-4.0)	265	30.94%	+4.57%
Custom + RF	153	32.68%	+11.08%

Analyses Clés :

- **Marge Bookmaker** : Les stratégies naïves et favoris perdent de l'argent malgré de bons taux de victoire.
- **Niche** : Seule la stratégie *Custom* (filtrage sélectif) est profitable.
- **Paradoxe ML** : L'IA a la meilleure précision (57.89%) mais un ROI nul. Tandis que la fusion de la stratégie *Custom* et de l'IA possède le meilleur ROI.

Ce que l'on observe :

- **Seuil $\uparrow \implies$ Win Rate $\uparrow$:**
L'IA ne garde que ses prédictions à très forte probabilité ($> 70\%$).
- **Seuil $\uparrow \implies$ ROI $\downarrow$:** Le rendement financier s'effondre en territoire négatif.

Le Phénomène de Refuge

Pour atteindre 72% de réussite, le RF élimine les cotes spéculatives et se réfugie **exclusivement** sur les grands favoris ($C_H \in [1.15; 1.30]$).

La Double Peine Financière

- ❶ **L'Overround** : Les bookmakers appliquent leur marge de sécurité maximale sur les favoris du grand public.
- ❷ **Efficience Parfaite** : Aucune erreur de cote n'est trouvable sur un match où le consensus est total.

Analyse Graphique : Les Matrices de Confusion




Figure 1 – Modèle Standard : Biais de classe majoritaire




Figure 2 – Modèle Rééquilibré (balanced) : Apparition des prédictions de nuls et explosion des faux positifs.

Analyse de Sensibilité : Le Paradoxe de Kelly

Fraction	Configuration (Grid Search)	ROI	Capital Final
0.10 (Prudent)	RF : $n_{\text{est}} = 100, d_{\text{max}} = 5, S_c = 0.0$	+7.46 %	119.36 €
0.70 (Optimum)	RF : $n_{\text{est}} = 100, d_{\text{max}} = 5, S_c = 0.0$	+6.73 %	202.72 €
0.95 (Agressif)	RF : $n_{\text{est}} = 100, d_{\text{max}} = 5, S_c = 0.0$	+4.57 %	176.76 €

Maximiser le ROI $\neq$ Maximiser le Profit

- **Zone de sous-exposition (0.10)** : ROI maximal, mais capital bridé par des mises infimes.
- **Optimum d'efficience (0.70)** : Le volume de mise active les intérêts composés $\implies$ **Capital doublé.**
- **Overbetting (0.95)** : Volatilité trop forte. Les séries de pertes détruisent l'effet multiplicateur.

Analyse : L'Efficiency du Marché et le Piège de l'Évidence

Configuration simulée	Nb. Paris	Win Rate	ROI Global
Écart Modéré = 3 Cote Min = 1.8	482	38.80 %	+3.25 %
Écart Massif = 8 Cote Min = 1.9	53	35.85 %	-16.55 %
Écart Massif = 8 Cote Min = 1.4	130	48.46 %	-12.92 %

Interprétation des Résultats

- **L'illusion des dynamiques fortes (Écart de 8) :** Chercher l'évidence absolue détruit le capital. Les bookmakers sur-ajustent agressivement les cotes lorsque l'écart de forme est flagrant pour le grand public.
- **La vraie valeur (Écart de 3) :** Le profit se cache dans les **asymétries subtiles**. Le marché sous-évalue parfois de légers décalages de forme, permettant d'être rentable sur le long terme (+3.25 %).

Technologies :

- Langage : Python 3.
- GUI : Tkinter (Thème Dark Mode).
- Matplotlib (Intégré).
- ML/NLP : Scikit-learn, TextBlob.

Interface Graphique

Modularité :

- 1 **Simulation** : Backtesting des heuristiques.
- 2 **Programme** : Visualisation des cotes.
- 3 **Prédictions** : Analyse Sentiment.
- 4 *Machine Learning* : Module indépendant.

Bilan

- Chaîne complète : Données → Modèle → Interface.
- **Précision** $\neq$ **Rentabilité** : L'IA prédit bien mais ne bat pas la marge seule. Cependant, l'IA permet d'augmenter nos chances de réussite sur une stratégie simple (30.94% -> 32.68%).
- La **spécialisation** (Custom) bat la généralisation.

Merci de votre attention

Place aux questions