

UNIVERSITÉ DE CAEN NORMANDIE

M1 INFORMATIQUE - Projet I

Simulation and Evaluation of Sports Betting Strategies

Rapport de Projet

Réalisé par le groupe :

Lawin DIRIK
Fantin VICO
Clément BOLIFRAUD

Enseignant :

M.SPANIOL

2 juin 2026

Table des matières

1	Introduction	3
2	Acquisition et Préparation des Données	3
2.1	Sources de Données	3
2.2	Nettoyage et Transformation	3
3	Méthodologie : Les Stratégies Implémentées	4
3.1	Approches Heuristiques (Statiques)	4
3.1.1	Stratégies Naïves	4
3.1.2	Stratégies basées sur le Risque	4
3.1.3	Stratégie Optimisée (Custom)	4
3.2	Approche Adaptative : Machine Learning (Random Forest)	5
3.2.1	Préparation des Données et Encodage	5
3.2.2	Fonctionnement de l'Algorithme Random Forest	5
3.2.3	Protocole d'Entraînement : Le Split Temporel	6
3.2.4	Stratégie Custom améliorée via Random Forest	6
3.2.5	Stratégie Filtrée par Seuil de Confiance	6
3.2.6	Optimisation par Grid Search	7
3.2.7	Gestion Dynamique du Capital : Le Critère de Kelly	7
4	Analyse de Sentiment et Intelligence Contextuelle	8
4.1	Traitement du Langage Naturel avec TextBlob et Newspaper3k	8
4.1.1	Extraction Ciblée et Calcul de la Polarité	8
4.1.2	Mécanisme de calcul de la polarité par TextBlob	8
4.2	Heuristique de Décision et Intégration au Pipeline	9
4.2.1	La limite du lexique métier : L'analyse tactique vs l'émotion	9
5	Résultats et Analyse	10
5.1	Analyse des résultats	10
5.2	Analyse du Compromis WinRate/Rendement	11
5.3	Interprétation du Phénomène	11
5.4	Analyse de la Matrice de Confusion et Biais de Classe	12
5.4.1	Le mécanisme du biais de la classe majoritaire	12
5.4.2	Absence de signature topologique et rupture d'extrapolation	12
5.4.3	Limites de la repondération : Le coût financier du paramètre balanced . .	13
5.5	Résultats de l'analyse de sentiment et analyse des performances	13
5.5.1	Détection efficace des asymétries d'information	14
5.5.2	Validation des signaux forts sur les favoris	14
5.5.3	Limites actuelles : L'incapacité à anticiper la neutralisation (Le Match Nul)	14
5.5.4	Efficacité du filtre d'abstention (RAS)	14
5.6	L'impact de la Fraction de Kelly	15
5.6.1	Le Paradoxe ROI / Capital Final	15
5.7	Analyse de la Stratégie Value Betting (Anomalie de Forme)	15
5.7.1	Stratégies à Faible Écart de Forme (Seuil = 3 points)	15
5.7.2	Stratégies à Fort Écart de Forme (Seuil = 8 points)	16
5.7.3	Conclusion sur l'Anomalie de Forme	16

6	Architecture Technique et Interface	16
6.1	Conception de l'Interface Graphique (GUI)	16
6.2	Module 1 : Simulation des Stratégies	17
6.3	Module 2 : Programme et Suivi des Cotes	17
6.3.1	Flux de Récupération des Données Live	17
6.3.2	Traitement des Données et Inférence par l'IA	17
6.4	Module 3 : Random Forest et Grid Search	18
6.4.1	Le Mode "Simulation Simple"	18
6.4.2	Le Mode "Grid Search"	19
6.5	Module 4 : Prédictions via Analyse de Sentiment	19
6.6	Module 5 : Forme et Prédiction IA	19
6.6.1	Le Tableau de Bord de Forme	19
6.6.2	Le Simulateur de Confrontation Directe	20
7	Répartition du Travail	20
8	Conclusion et Perspectives	21
A	Annexes : Visuels de l'Interface	23

1 Introduction

Le marché des paris sportifs représente aujourd'hui une industrie colossale, générant plusieurs milliards d'euros de chiffre d'affaires annuel à l'échelle mondiale. Attirant un public allant du parieur occasionnel au professionnel, ce secteur repose néanmoins sur une asymétrie fondamentale : l'avantage mathématique du bookmaker.

En effet, les cotes proposées par les opérateurs ne sont pas une traduction directe des probabilités réelles d'un événement, mais incluent une marge (ou *overround*) qui assure un profit quasi-systématique à l'organisateur sur le long terme. Dès lors, pour la grande majorité des parieurs se fiant à leur intuition ou à leur attachement émotionnel à une équipe, l'espérance de gain est négative.

Cependant, l'avènement de la science des données et de l'intelligence artificielle ouvre de nouvelles perspectives. La problématique centrale de ce projet est donc la suivante : **est-il possible de développer des stratégies algorithmiques, heuristiques ou adaptatives, capables de surmonter la marge du bookmaker et de générer un profit sur le long terme ?**

Pour répondre à cette question, nous avons mené une étude de simulation basée sur des données historiques réelles. Les objectifs de ce projet se déclinent en quatre points principaux :

- **Constitution d'un jeu de données** : Collecte et nettoyage de l'historique des matchs et des cotes de la *Premier League* anglaise (source : *football-data.co.uk*).
- **Implémentation de stratégies** : Développement d'algorithmes allant d'heuristiques simples (ex : parier systématiquement sur le favori) à des approches adaptatives basées sur le *Machine Learning* (Random Forest) et l'analyse de sentiment.
- **Simulation et Évaluation** : Mise en place de *backtesting* simulant un portefeuille virtuel de 100€, permettant de mesurer le retour sur investissement (ROI) et l'évolution du capital pour chaque stratégie.
- **Développement d'outils** : Création d'une interface graphique (GUI) en Python pour faciliter le paramétrage des simulations et la visualisation des résultats.

Ce rapport présente la méthodologie employée, l'architecture technique de notre solution, ainsi qu'une analyse critique des résultats obtenus pour chaque famille de stratégies.

2 Acquisition et Préparation des Données

La qualité des prédictions dépend directement de la richesse des données collectées. Notre projet s'appuie sur une architecture de données hybride combinant archives historiques et flux en temps réel.

2.1 Sources de Données

- **Données Historiques (Backtesting)** : Nous utilisons les fichiers CSV de *football-data.co.uk* couvrant les saisons passées de la Premier League. Ces fichiers contiennent les résultats (FTR) et les cotes de fermeture de plusieurs bookmakers. Les saisons vont de fin 2020 à début 2024 (soit un total de 4 saisons de Premier League qui représentent plus de 1500 matchs).
- **Données Temps Réel (The Odds API)** : Pour la partie prédiction des matchs à venir, nous interrogeons l'API *The Odds API*. Elle nous fournit les cotes décimales actualisées pour le marché 1N2 (H2H) auprès de bookmakers comme Bet365 ou Pinnacle.
- **Flux d'Informations (NewsAPI)** : Afin d'intégrer une dimension contextuelle, nous récupérerons les 5 derniers articles de presse mondiale pour chaque équipe via l'API *NewsAPI*.

2.2 Nettoyage et Transformation

Avant toute analyse, les données subissent un traitement rigoureux (pipeline `charger_donnees.py`) :

- **Normalisation des dates** : Conversion des formats de chaînes de caractères en objets `datetime` Python pour permettre les calculs de délais (ex : J+1, J+4).
- **Gestion des valeurs manquantes** : Suppression ou imputation des matchs ne disposant pas de cotes complètes afin d'éviter les biais dans le calcul du ROI.
- **Ingénierie des caractéristiques (Feature Engineering)** : Création de variables synthétiques comme la moyenne des sentiments ou l'écart de cotes entre le favori et l'outsider.

3 Méthodologie : Les Stratégies Implémentées

Cette section détaille les algorithmes de décision développés pour simuler les paris. Nous avons divisé notre approche en deux catégories : les heuristiques statiques (règles fixes) et les approches adaptatives (basées sur l'apprentissage automatique).

3.1 Approches Heuristiques (Statiques)

Les stratégies heuristiques reposent sur des règles de décision prédéterminées et immuables, quelles que soient les dynamiques temporelles ou les informations contextuelles (blessures, météo, etc.). Elles servent principalement de benchmark pour évaluer la difficulté du marché.

3.1.1 Stratégies Naïves

Implémentées dans le fichier `heuristic_homeAwayDraw.py`, ces stratégies parient systématiquement sur la même issue pour chaque match, sans tenir compte des cotes.

- **Toujours Domicile (Home)** : On parie sur l'équipe locale à chaque match. Cette stratégie exploite l'avantage du terrain.
- **Toujours Extérieur (Away)** : On parie systématiquement sur l'équipe visiteuse.
- **Toujours Nul (Draw)** : On parie systématiquement sur un match nul.

L'objectif est de vérifier si le simple fait de suivre la tendance statistique majoritaire (victoire à domicile) suffit à compenser la marge du bookmaker.

3.1.2 Stratégies basées sur le Risque

Implémentées dans `heuristic_risk.py`, ces stratégies introduisent une comparaison entre les cotes proposées par le bookmaker (Bet365). Pour un match donné opposant une équipe H (Home) et A (Away) avec des cotes respectives C_H et C_A :

- **Low-Risk (Favori)** : L'algorithme identifie la cote la plus faible et parie dessus.

$$\text{Choix} = \begin{cases} H & \text{si } C_H < C_A \\ A & \text{si } C_A < C_H \end{cases}$$

Cette approche maximise le taux de réussite (nombre de paris gagnés) mais offre des gains unitaires faibles.

- **High-Risk (Outsider)** : À l'inverse, l'algorithme parie systématiquement sur la cote la plus élevée (l'issue la moins probable selon le bookmaker). Bien que le taux de réussite soit attendu comme très faible, l'espérance est qu'un seul gain couvre plusieurs pertes grâce à une cote élevée.

3.1.3 Stratégie Optimisée (Custom)

Nous avons développé une stratégie "maison" dans le fichier `heuristic_custom.py`, visant à identifier des Value Bets potentiels sur les équipes à l'extérieur.

L'analyse exploratoire des données a suggéré que les bookmakers sous-estiment parfois certaines équipes visiteuses situées dans une gamme de cotes intermédiaire. La règle implémentée est la suivante :

- Parier sur l'équipe à l'**Extérieur (Away)** si et seulement si sa cote C_A est comprise dans l'intervalle :

$$3.0 \leq C_A < 4.0$$

Cette heuristique tente d'éviter les paris trop risqués (cotes > 4.0 où la victoire est improbable) tout en cherchant des gains significatifs (cotes ≥ 3.0), filtrant ainsi drastiquement le nombre de paris engagés par rapport aux stratégies naïves.

3.2 Approche Adaptative : Machine Learning (Random Forest)

Contrairement aux heuristiques qui appliquent des règles figées, l'approche adaptative cherche à modéliser mathématiquement la relation complexe entre les caractéristiques d'un match et son résultat. Pour ce projet, nous avons implémenté un classifieur de type **Random Forest** via la bibliothèque `scikit-learn`.

3.2.1 Préparation des Données et Encodage

Les algorithmes de Machine Learning ne pouvant traiter des données textuelles brutes, une phase de pré-traitement est nécessaire (fonction `preparer_donnees_ml` dans `random_forest.py`) :

- **Encodage des équipes** : Les noms des équipes (ex : "Arsenal", "Chelsea") sont convertis en entiers uniques via un *Label Encoding*. Cela permet au modèle d'identifier les équipes sans ambiguïté.
- **Variables explicatives (X)** : Le modèle est entraîné sur un vecteur de caractéristiques comprenant l'identifiant de l'équipe à domicile, l'identifiant de l'équipe à l'extérieur, ainsi que les trois cotes proposées par le bookmaker ($C_{Home}, C_{Draw}, C_{Away}$). L'inclusion des cotes est cruciale car elles agrègent déjà une grande quantité d'informations (forme, blessures) analysées par le bookmaker.
- **Variable cible (y)** : Le résultat du match (FTR) est encodé en classes numériques (ex : 0 =Home, 1 =Draw, 2 =Away).

3.2.2 Fonctionnement de l'Algorithme Random Forest

Le Random Forest est une méthode d'apprentissage d'ensemble qui combine les prédictions de plusieurs arbres de décision pour améliorer la robustesse et la précision du modèle global. Son fonctionnement repose sur deux principes fondamentaux :

1. **Le Bagging (Bootstrap Aggregating)** : L'algorithme génère N arbres de décision indépendants (paramètre `n_estimators`). Chaque arbre est entraîné sur un sous-ensemble aléatoire des données d'entraînement, tiré avec remise. Cela permet de créer une diversité dans les modèles : chaque arbre "voit" une version légèrement différente de l'histoire.
2. **Aléatoire des caractéristiques** : À chaque nœud de décision d'un arbre, l'algorithme ne considère qu'un sous-ensemble aléatoire des variables explicatives pour trouver la meilleure séparation. Cela évite que les arbres ne soient trop corrélés entre eux (par exemple, si une variable est trop dominante).

Le processus de prédiction : Lorsqu'un nouveau match (du jeu de test) est présenté au modèle, chaque arbre de la forêt émet un vote (une prédiction de classe : Victoire H, Nul ou Victoire A). Le Random Forest agrège ces votes et la classe qui obtient la majorité l'emporte.

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_n(x)\}$$

Cette approche par "vote majoritaire" permet de réduire considérablement le risque de sur-apprentissage par rapport à un arbre de décision unique.

3.2.3 Protocole d'Entraînement : Le Split Temporel

Un point critique dans la simulation de paris sportifs est d'éviter d'utiliser des informations du futur pour prédire le passé.

Contrairement aux séparations classiques aléatoires (`shuffle=True`), nous avons implémenté une **séparation chronologique stricte** :

- Les données sont triées par date.
- **Jeu d'entraînement (Train Set)** : Les 80% premiers matchs de l'historique. Le modèle apprend les corrélations sur cette période passée.
- **Jeu de test (Test Set)** : Les 20% derniers matchs. C'est sur cette période "future" (du point de vue du modèle) que la simulation d'investissement est effectuée.

Ainsi, lorsque le modèle parie sur un match du jeu de test, il n'a jamais "vu" ce match ni aucun match ultérieur lors de sa phase d'apprentissage, garantissant l'intégrité de la simulation.

3.2.4 Stratégie Custom améliorée via Random Forest

Pour affiner notre stratégie de *Value Betting*, nous avons fait évoluer l'heuristique initiale (`heuristic_custom.py`) en y intégrant un modèle prédictif de classification de type **Random Forest**.

L'approche initiale reposait uniquement sur un filtre de cotes fixe. La nouvelle stratégie combine cette approche empirique avec la puissance du *Machine Learning* pour valider mathématiquement la présence d'une valeur attendue, structurée selon les deux étapes suivantes :

1. **Filtrage par l'Heuristique** : Nous conservons le filtre exploratoire sur les équipes visiteuses présentant une gamme de cotes intermédiaire, car cet intervalle a démontré historiquement un biais de sous-estimation de la part des bookmakers :

$$3.0 \leq C_A < 4.0$$

2. **Validation par Random Forest** : Pour chaque match sélectionné par le filtre, le modèle Random Forest — entraîné sur les caractéristiques historiques des équipes — estime la probabilité intrinsèque de victoire de l'équipe à l'extérieur, notée $P(Away)$.

Un pari n'est effectivement engagé que si l'espérance de gain (*Expected Value*) est jugée statistiquement avantageuse. Nous avons fixé un seuil strict où l'avantage estimé doit être supérieur ou égal à 5 % face à la cote du bookmaker :

$$P(Away) \times C_A \geq 1.05$$

Gestion du Capital (Mise Fixe) Contrairement aux approches de mise proportionnelle, cette stratégie applique une gestion des risques prudente par **mise fixe** (*Flat Betting*). Pour chaque opportunité validée par le modèle, un montant invariant ($M = 1$ unité) est engagé. Cette méthodologie standardise l'exposition au risque et permet d'évaluer la robustesse pure des prédictions du modèle face à la variance, sans dépendre de la fluctuation de la taille des mises

On a aussi implémenté la formule de Kelly dans cette stratégie, mais cette dernière renvoyait un ROI bien inférieur (0.98% ROI). Nous avons donc décidé de retirer cette formule.

3.2.5 Stratégie Filtrée par Seuil de Confiance

Le comportement natif d'un classifieur **Random Forest** consiste à émettre une prédiction systématique pour chaque observation qui lui est présentée. Cela contraindrait l'algorithme à placer un pari sur l'intégralité des matchs du jeu de test, y compris ceux pour lesquels les critères de décision sont hautement indécis. Pour pallier ce problème et maximiser le ROI, nous avons introduit un paramètre de **seuil de confiance** (S_c) agissant comme un filtre décisionnel.

Le formalisme mathématique de predict_proba Plutôt que d'exploiter la prédiction brute par vote majoritaire $\hat{y}$, l'algorithme extrait le vecteur des probabilités a posteriori pour chaque issue possible via la méthode `predict_proba` :

$$P(Y = k | x) = \frac{1}{N} \sum_{i=1}^N P_i(Y = k | x)$$

Où N représente le nombre total d'arbres (`n_estimators`) et $P_i(Y = k | x)$ désigne la proportion empirique de la classe k au sein de la feuille terminale dans laquelle l'observation x a échoué pour l'arbre i . La moyenne de ces proportions engendre des probabilités continues fines.

L'indice de confiance du modèle, noté $\mathcal{C}(x)$, correspond à la probabilité maximale affectée à l'issue prédite :

$$\mathcal{C}(x) = \max_{k \in \{0,1,2\}} P(Y = k | x)$$

Mécanisme du filtre d'abstention La règle d'engagement des capitaux sur un match donné est alors régie par l'inéquation suivante : Décision de pari = Parier sur la classe si $\mathcal{C}(x) \geq S_c$
Abstention si $\mathcal{C}(x) < S_c$

En fixant par exemple $S_c = 0.60$, on contraint le modèle à n'engager une mise que si la convergence des arbres de la forêt attribue une probabilité d'au moins 60% à l'issue sélectionnée.

3.2.6 Optimisation par Grid Search

La performance et la robustesse du modèle dépendent du choix des hyperparamètres du Random Forest ($N_{\text{estimators}}$ et $\text{Max}_{\text{depth}}$) ainsi que du Seuil. Pour trouver la combinaison optimale, nous avons implémenté un algorithme de **Grid Search** personnalisé (`gridsearchRF.py`).

3.2.7 Gestion Dynamique du Capital : Le Critère de Kelly

Au-delà de la capacité d'un modèle à prédire l'issue d'une rencontre, la rentabilité à long terme d'une stratégie de paris sportifs dépend de manière cruciale de la gestion du capital. Les stratégies à mise fixe (*flat betting*), bien que sécurisantes, ne tirent pas pleinement parti de la variabilité de la confiance du modèle. Pour pallier cette limitation, nous avons implémenté le **Critère de Kelly**, une formule mathématique utilisée pour déterminer la taille optimale d'une série de paris afin de maximiser le taux de croissance du capital sur le long terme.

Le principe fondamental de Kelly est d'ajuster le montant misé en fonction de la taille de l'avantage (la "Value") identifié par l'algorithme. La formule classique du critère de Kelly se définit ainsi :

$$f^* = \frac{p \cdot b - q}{b} = p - \frac{q}{b}$$

Où :

- f^* représente la fraction optimale du capital actuel à miser.
- p est la probabilité de victoire estimée par notre modèle (Random Forest).
- q est la probabilité de perte ($q = 1 - p$).
- b est le profit net espéré par unité mise ($b = \text{Cote décimale} - 1$).

Rôle de Filtre et Optimisation du Rendement L'intégration de cette formule agit comme un filtre décisionnel. Si $f^* \leq 0$, cela signifie que la probabilité estimée par l'IA ne justifie pas le risque compte tenu de la cote proposée par le bookmaker. L'algorithme rejette alors automatiquement l'opportunité. À l'inverse, un $f^* > 0$ valide un avantage mathématique, et la formule dicte de miser un pourcentage précis du capital disponible. Ainsi, le modèle mise davantage sur des situations jugées rentables et réduit l'exposition sur des paris marginaux.

Implémentation du Fractional Kelly Le critère de Kelly pur présente néanmoins un défaut en pratique : son extrême volatilité. Dans des cas très favorables, la formule peut recommander d’engager une portion colossale de la *bankroll* (parfois supérieure à 30 % ou 40 %), augmentant significativement le risque de ruine lors d’une variance négative inévitable.

Pour mitiger ce risque, notre approche algorithmique emploie un **Fractional Kelly** (généralement un quart, soit un multiplicateur de 0.25). Cette approche conservatrice sacrifie une partie de la croissance théorique maximale pour lisser drastiquement la courbe de l’évolution du capital et préserver l’investisseur. De plus, un plafond strict de sécurité a été codé en dur, limitant toute mise maximale à 15 % du capital courant, garantissant ainsi la pérennité de l’investissement face aux imprévus inhérents au sport.

4 Analyse de Sentiment et Intelligence Contextuelle

Cette section détaille notre approche visant à surpasser les modèles purement statistiques en intégrant une dimension contextuelle et médiatique via le Traitement du Langage Naturel (NLP). Nous avons fait évoluer notre pipeline, pour pouvoir analyser dans son intégralité le corps de l’article, et ne pas s’arrêter simplement au titre.

4.1 Traitement du Langage Naturel avec TextBlob et Newspaper3k

L’analyse s’appuie conjointement sur l’API NewsAPI pour l’agrégation des sources, la bibliothèque `newspaper3k` pour le scraping du contenu complet, et `TextBlob` pour l’évaluation sémantique.

4.1.1 Extraction Ciblée et Calcul de la Polarité

Plutôt que d’évaluer le sentiment global d’un article qui pourrait traiter de multiples sujets ou équipes, notre algorithme effectue une extraction contextuelle ciblée. Le processus technique opère selon les étapes suivantes :

1. **Collecte et Filtrage à la source** : L’API interroge jusqu’à 60 URL d’articles récents mentionnant l’équipe en Premier League. Un filtre de qualité ignore automatiquement les domaines non pertinents ou bloquants (tels que Yahoo, MSN, ou les pop-ups de consentement).
2. **Scraping Intégral** : Pour chaque lien valide, le texte complet de l’article est téléchargé et extrait de sa structure HTML via la classe `Article` de `newspaper3k`.
3. **Isolement Sémantique (Filtrage contextuel)** : Le corps du texte est découpé en phrases. Afin d’éviter de capter le sentiment d’un paragraphe parlant d’un autre sujet, l’algorithme ne conserve et ne concatène que les phrases contenant explicitement un mot-clé lié au nom de l’équipe.
4. **Évaluation** : Ce bloc de phrases hautement pertinentes est analysé par `TextBlob` pour générer un score de polarité compris entre -1 (très négatif) et 1 (très positif).

Pour chaque équipe, ce processus itératif s’arrête dès que l’algorithme a validé et scoré $n = 8$ articles de qualité. Le score final de l’équipe est la moyenne de ces polarités :

$$Score_{Sentiment} = \frac{\sum_{i=1}^n P_i}{n}$$

4.1.2 Mécanisme de calcul de la polarité par TextBlob

Pour transformer le texte isolé en un score numérique, `TextBlob` utilise l’analyseur `PatternAnalyzer`, basé sur une approche lexicale. Le processus suit quatre grandes étapes :

1. **Tokenisation et Filtrage** : Le texte extrait est décomposé en mots individuels (*tokens*), en ignorant les mots fonctionnels sans charge sémantique.
2. **Recherche Lexicale** : Chaque mot restant est comparé à un dictionnaire interne assignant des scores de polarité (ex : "*win*" possède une valeur positive forte, "*injury*" une valeur négative).
3. **Gestion des Modificateurs (*Valence Shifters*)** : L'algorithme détecte la syntaxe autour des adjectifs :
 - **Négation** : L'usage de "*not*" inverse la polarité du mot suivant.
 - **Intensification** : Un adverbe comme "*very*" agit comme un multiplicateur d'intensité sur le sentiment détecté.
4. **Agrégation Finale** : La polarité des phrases conservées est calculée par la moyenne des scores pondérés des mots porteurs identifiés.

4.2 Heuristique de Décision et Intégration au Pipeline

L'interprétation du score de sentiment généré est directement exploitée par notre pipeline de prédiction des rencontres à venir (`run_prediction_pipeline`).

Justification du seuil d'activation à 0.20 : Lors du traitement des affiches récupérées via *The Odds API*, l'algorithme calcule simultanément le sentiment pour l'équipe à domicile et à l'extérieur. L'heuristique de prise de décision dicte qu'une recommandation de pari ("*BET*") n'est générée que si le score d'une équipe franchit le seuil strict de 0.20.

- **De 0.0 à 0.15** : Le climat médiatique autour de l'équipe est jugé neutre ou purement factuel.
- **De 0.15 à 0.30** : Le seuil de 0.20 matérialise une **dynamique positive** affirmée dans la presse. Cela signale un contexte favorable (retour d'un joueur cadre, confiance de l'entraîneur) suffisant pour constituer un avantage psychologique.
- **Au-delà de 0.50** : Indique un état d'euphorie médiatique (très rare dans le sport de haut niveau).

Amélioration de la Robustesse : Le passage d'une analyse restreinte à des titres pour 5 articles vers l'exploration du contenu textuel complet pour 8 sources fiables marque une évolution de la qualité du modèle. En isolant les phrases associées au nom du club, le système annule l'effet de "bruit" (les mentions d'autres équipes dans le même article) et offre un indicateur fidèle de l'état de forme psychologique réel des effectifs.

4.2.1 La limite du lexique métier : L'analyse tactique vs l'émotion

Un autre biais structurel rencontré lors de nos tests réside dans la nature même de l'outil `TextBlob` : son approche par dictionnaire généraliste. Le modèle excelle pour capter l'euphorie ou la crise (le vocabulaire émotionnel), mais se révèle inadapté face à la presse d'analyse tactique.

Lorsqu'un article de fond décrit une équipe comme étant "tactiquement en place", "structurée", possédant un "bloc défensif compact" ou exploitant bien "les transitions rapides", le journaliste décrit factuellement une équipe très performante. Cependant, ce lexique technique est dépourvu de charge émotionnelle dans le dictionnaire standard de l'algorithme.

Par conséquent, ces articles à forte valeur prédictive génèrent des scores de polarité neutres (proches de 0.0). L'algorithme échoue ainsi à valoriser des signaux sportifs pourtant cruciaux, diluant le score final de l'équipe et empêchant potentiellement le franchissement du seuil d'activation de 0.20.

5 Résultats et Analyse

Cette section présente les performances des différentes approches heuristiques appliquées sur le dataset des matchs de la Premier League 2025. Les métriques évaluées sont le retour sur investissement (ROI), le taux de victoire (Win Rate) et le volume de paris effectués.

TABLE 1 – Comparaison des performances des stratégies heuristiques (Premier League 2025)

Stratégie	Nb. de Paris	Taux de Victoire	ROI
<i>Stratégies Naïves</i>			
Toujours Domicile	617	38.74%	-16.12%
Toujours Extérieur	1520	33.82%	-1.46%
Toujours Nul	916	22.49%	-10.81%
<i>Stratégies basées sur le Risque</i>			
Low-Risk (Favori)	1507	56.47%	-1.11%
High-Risk (Outsider)	1507	21.30%	-6.31%
<i>Stratégie Optimisée</i>			
Custom ($3.0 \leq \text{Cote} < 4.0$)	265	30.94%	+4.57%
<i>Via machine learning</i>			
80 % dataset learning 20% test	304	57.89%	0.16%
RF via stratégie custom	154	32.68%	+11.08%
RF + Kelly (Fraction=0.70)	304	57.89%	+6.73%

5.1 Analyse des résultats

Les résultats résumés dans le Tableau 1 mettent en évidence plusieurs points clés :

- **Échec des stratégies naïves** : On se rends compte que parier aveuglément sur une issue (Domicile, Extérieur ou Nul) conduit systématiquement à une perte. D'où l'importance des côtes.
- **Performance du Favori** : La stratégie *Low-Risk*, bien qu'affichant un taux de réussite élevé (56.47%), ne parvient pas à être rentable (-1.11% ROI), suggérant que les cotes des favoris sont souvent ajustées pour minimiser les gains des parieurs.
- **Efficacité de la stratégie Custom** : Seule la stratégie optimisée, basée sur les sous-estimations des équipes obtient un résultat positif. Cette cible les équipes visitrices avec des cotes comprises entre 3.0 et 4.0 et parvient à dégager un profit net (**+4.57% ROI**). Bien que le volume de paris soit plus faible (265 paris), ce filtrage sélectif permet d'identifier des *value bets* que les stratégies généralistes manquent.
- **Ajout du Random Forest à la stratégie gagnante** : Nous avons ensuite entraîné un modèle d'IA basé sur le modèle de prédiction du random Forest pour augmenter notre taux de réussite sur notre stratégie custom. On observe une augmentation du taux de victoire de quelques % (2% environ). Cette légère augmentation nous a notamment permis d'augmenter notre ROI de 4.57% à 11.08%.
- **Performance du Machine Learning** : L'approche ML se distingue par le ****taux de réussite le plus élevé (57.89%)****, surpassant même la stratégie consistant à parier systématiquement sur les favoris (56.47%). Cependant, le ROI est quasi-nul (0.16%), indiquant une situation de "break-even". Le modèle parvient à prédire correctement l'issue des matchs, mais la marge du bookmaker absorbe la totalité des profits potentiels. Cela suggère un modèle "sûr" mais prudent, qui s'aligne souvent sur les cotes du marché sans trouver assez de "value bets".

- **Efficacité de la Gestion de Portefeuille (Critère de Kelly)** : L'intégration de la formule de Kelly permet une meilleure gestion du capital et en conséquence de meilleure performance. Avec une fraction de 0.70 appliquée sur les prédictions brutes du Random Forest, le modèle conserve son taux de victoire (57.89%) tout en dégagant un ROI très solide de +6.73%. Surtout, la capacité du modèle à faire varier proportionnellement le volume de ses mises lors des opportunités à forte espérance permet d'exploiter la puissance des intérêts composés. **Le capital final de 202.72 € dépasse les autres méthodes**, prouvant que la clé d'un investissement sportif ne réside pas uniquement dans la capacité à deviner l'issue d'un match, mais réside aussi dans l'optimisation du montant risqué.

5.2 Analyse du Compromis WinRate/Rendement

L'exploitation des combinaisons issues du *Grid Search* permet d'étudier l'influence du filtre probabiliste sur l'efficacité de la stratégie d'investissement. Les données mettent en évidence trois dynamiques distinctes :

Scénario / Profil	Configuration ($n_{\text{est}}, d_{\text{max}}, S_c$)	Nb. Paris	Win Rate	ROI	Capital Final
1. Agressif	(50, 5, 0.00)	304	58.22%	+1.60%	104.85 €
2. Équilibré	(50, 5, 0.40)	254	61.02%	+0.35%	100.88 €
3. Sécurisé	(50, 5, 0.70)	54	72.22%	-8.54%	95.39 €

TABLE 2 – Impact du Seuil sur la performance du Random Forest

- **Le profil Agressif ou "Volume maximal"** ($S_c = 0.00$) : Lorsque le modèle est forcé de se positionner sur l'intégralité des 304 matchs du jeu de test, la configuration optimale ((50, 5, 0.00)) parvient à capter un ROI positif de +1.60% avec un *Win Rate* de 58.22%.
- **Le profil Équilibré** ($S_c = 0.40$) : En introduisant une barrière d'abstention légère à 40%, le modèle filtre les rencontres où les arbres sont en situation d'indécision totale. Pour la configuration (50, 5, 0.40), le volume de transactions se contracte (254 paris), mais la précision grimpe mécaniquement à **61.02%** pour un ROI de +0.35%.
- **La saturation du profil Sécurisé** ($S_c = 0.70$) : À l'extrême inverse, la configuration (50, 5, 0.70) illustre les limites de la quête de certitude absolue sur un marché de paris. En exigeant un consensus d'au moins 70% de la part des arbres, le modèle atteint un taux de réussite exceptionnel de **72.22%** (soit environ 3 matchs sur 4 correctement prédits). Cependant, son ROI s'effondre dans le négatif à **-8.54%**.

5.3 Interprétation du Phénomène

Ce grand écart entre un taux de victoire maximal (72.22%) et un rendement négatif s'explique par la structure même des cotes des bookmakers. En poussant le seuil de confiance à un niveau aussi restrictif, le *Random Forest* élimine tous les paris spéculatifs (matchs nuls ou victoires d'outsiders à cotes élevées) pour se réfugier exclusivement sur les très grands favoris à domicile (ex : Manchester City ou Arsenal avec des cotes comprises entre 1.15 et 1.30).

Or, les cotes des grands favoris subissent de plein fouet deux phénomènes délétères :

1. **L'Overround** : Les bookmakers appliquent une marge de sécurité plus agressive sur les favoris car ils savent que le grand public a tendance à sur-parier sur ces équipes.
2. **L'absence d'asymétrie d'information** : Il est impossible de trouver une erreur de cotation sur un match où l'unanimité du marché est déjà totale.

En conclusion, le *Grid Search* démontre qu’une stratégie gagnante sur les marchés sportifs ne cherche pas la certitude absolue. Le meilleur modèle économique s’établit à la frontière des profils Agressif et Équilibré ($0.00 \leq S_c \leq 0.40$), là où le modèle accepte une part de variance en échange de cotes suffisamment rémunératrices pour battre la marge structurelle du bookmaker.

5.4 Analyse de la Matrice de Confusion et Biais de Classe

L’évaluation globale du classifieur de type *Random Forest* par son exactitude (*Accuracy*) ou de son taux de réussite brut peut s’avérer trompeur sur les marchés prédictifs sportifs. L’analyse de la matrice de confusion ici : **Figure 1**. de notre modèle a mis en avant une anomalie structurelle majeure : **l’algorithme ne prédit presque jamais la classe du match nul ($2 = \text{Draw}$)**.

Pour comprendre ce comportement mathématique et évaluer la robustesse des frontières de décision, nous avons soumis le modèle à un test de stress unitaire au sein de notre simulateur Face-à-Face, en lui injectant une cote fictive aberrante de 1.10 sur le match nul. Le modèle a persisté à prédire une victoire (H ou A).

5.4.1 Le mécanisme du biais de la classe majoritaire

En football, la distribution des résultats réels présente un déséquilibre de classe inhérent : les victoires à domicile (H) et à l’extérieur (A) agrègent historiquement près de 75% à 78% des issues, reléguant le match nul (D) au statut de classe minoritaire ($\approx 22\%$).

Lors de sa phase d’apprentissage (`.fit()`), la fonction objective du *Random Forest* cherche à maximiser le gain d’information (entropie ou impureté de Gini). L’arbre de décision segmente l’espace vectoriel en fonction des variables explicatives disponibles, à savoir les cotes des bookmakers ($C_{\text{Home}}, C_{\text{Draw}}, C_{\text{Away}}$). * Une cote C_{Home} très faible (< 1.40) est corrélée de manière quasi-univoque à la classe 0 (Home). * Une cote C_{Away} très faible est corrélée à la classe 2 (Away). * En revanche, les cotes du match nul (C_{Draw}) sont structurellement stables et confinées dans une fourchette étroite, généralement comprise entre 3.00 et 4.50. Il n’existe aucun antécédent historique où un bookmaker propose une cote de match nul ultra-favorite (par exemple à 1.20).

Par conséquent, dans toutes les régions de l’espace où le match est équilibré, la feuille terminale de l’arbre contient une distribution probabiliste du type : 38% de H, 38% de A et 24% de D. Bien que la probabilité du nul soit significative, elle n’est **jamais majoritaire**. Par l’application de la règle du vote majoritaire (le mode des estimateurs) :

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_n(x)\}$$

Le modèle élimine systématiquement la classe minoritaire pour minimiser son taux d’erreur global sur le jeu d’entraînement.

5.4.2 Absence de signature topologique et rupture d’extrapolation

Le fait que l’injection manuelle d’une cote de match nul à 1.10 dans le module Face-à-Face n’altère pas la prédiction de l’IA illustre le concept mathématique de **rupture d’extrapolation en dehors de la distribution d’apprentissage** (*Out-of-Distribution* ou OOD).

Un modèle de *Machine Learning* n’acquiert aucune sémantique métier : il ne sait pas qu’une cote faible symbolise une forte probabilité de réalisation. Il applique de pures frontières géométriques de coupure apprises sur son échantillon statistique. N’ayant jamais observé de valeur $C_{\text{Draw}} < 2.50$ dans le *Train Set*, l’algorithme n’a configuré aucun nœud décisionnel capable de traiter cette anomalie sur cette colonne spécifique.

Lors de l'évaluation, le vecteur de test aberrant :

$$x_{\text{aberrant}} = [\text{Home_Code}, \text{Away_Code}, 2.50, \mathbf{1.10}, 2.80]$$

traverse les nœuds de l'arbre. La condition historique apprise sur le nul, telle que "si $C_{\text{Draw}} \geq 2.80$ ", renvoie la valeur **Faux**. L'observation est alors déroutée vers une branche par défaut. L'algorithme se rabat alors exclusivement sur les frontières qu'il maîtrise : le code d'identification des équipes ou le rapport de force entre les cotes C_{Home} et C_{Away} , ignorant totalement le signal forcé sur le nul.

5.4.3 Limites de la repondération : Le coût financier du paramètre balanced

Pour tenter de corriger ce biais géométrique et forcer l'algorithme à envisager des scores de parité, notre approche consiste à introduire une pénalité inversement proportionnelle à la fréquence des classes lors du calcul de l'impureté de Gini (via l'argument `class_weight="balanced"` sous `scikit-learn`). Mathématiquement, cela modifie la fonction de coût en attribuant un poids artificiellement trois fois supérieur à la classe du match nul ($2 = \text{Draw}$) :

$$I_{\text{Gini}}(p) = 1 - \sum_{k \in \{0,1,2\}} (w_k \cdot p_k)^2$$

L'expérimentation de cette méthode au sein de notre protocole de simulation a révélé un comportement paradoxal **Figure 2** :

- **Validation technique** : La repondération remplit son rôle algorithmique initial. Les arbres configurent de nouvelles subdivisions dédiées au nul et le modèle commence à générer des prédictions de type "Draw" dans la matrice de confusion.
- **Baisse drastique du ROI** : Cependant, cette sensibilité se traduit par une dégradation immédiate du Retour sur Investissement. Le match nul étant par nature un événement à très difficiles à anticiper avec précision, le modèle génère un volume massif de **faux positifs** (des rencontres prédites comme nulles qui se soldent en réalité par la victoire d'une des deux équipes).

Chaque faux positif équivalant à une perte de la mise unitaire, le coût financier de l'erreur sur le marché du nul s'avère supérieur au gain des quelques prédictions correctes.

Cet enseignement confirme qu'une solution mathématiquement "équilibrée" à un problème de classification peut s'avérer économiquement destructive.

5.5 Résultats de l'analyse de sentiment et analyse des performances

TABLE 3 – Prédictions issues de l'Analyse de Sentiment et Résultats Réels

Date	Match	Cote H	Cote N	Cote A	Sent. H	Sent. A	Décision	Résultat Réel
2026-03-16	Brentford vs Wolverhampton Wanderers	1.58	4.25	5.9	0.3	0.0	BET Brentford	NUL
2026-03-20	Bournemouth vs Manchester United	3.09	3.76	2.25	0.17	0.23	BET Manchester United	NUL
2026-03-21	Brighton and Hove Albion vs Liverpool	3.19	3.76	2.20	0.25	0.20	BET Brighton	Brighton
2026-03-21	Fulham vs Burnley	1.57	4.19	6.19	0.22	0.17	BET Fulham	Fulham
2026-03-21	Everton vs Chelsea	3.63	3.62	2.07	0.34	0.17	BET Everton	Everton
2026-03-21	Leeds United vs Brentford	2.57	3.52	2.79	0.08	0.11	RAS	NUL
2026-04-20	Crystal Palace vs West Ham United	2.35	3.25	3.00	0.08	0.00	RAS	NUL

Le tableau 3 présente un échantillon de prédictions générées par notre pipeline d'analyse de sentiment (TextBlob), confrontées aux cotes réelles du marché et aux résultats observés sur le terrain. L'analyse de ces données permet de tirer plusieurs enseignements qualitatifs sur la pertinence et les limites de l'approche textuelle.

5.5.1 Détection efficace des asymétries d'information

L'un des apports majeurs de ce modèle est sa capacité à identifier des *Value Bets* ignorés par les statistiques pures en captant l'inertie médiatique. Les rencontres du 21 mars 2026 l'illustrent parfaitement :

- **Everton vs Chelsea** : Bien qu'Everton soit clairement considéré comme l'outsider par les bookmakers (Cote $H = 3.63$), le modèle détecte un bon sentiment autour du club (0.34, le score le plus élevé de l'échantillon). La décision *BET Everton* s'avère exacte.
- **Brighton vs Liverpool** : Dans une configuration similaire, Liverpool est favori ($C_A = 2.20$), mais la dynamique textuelle est à l'avantage de Brighton (0.25 vs 0.20). Le modèle choisit l'outsider avec succès ($C_H = 3.19$).

Ces succès confirment que la presse sportive agit souvent comme un indicateur intéressant de la performance d'une équipe, pouvant parfois dépasser le bookmaker, et tirer profit de nos résultats.

5.5.2 Validation des signaux forts sur les favoris

L'analyse de sentiment confirme également son utilité lorsqu'elle s'aligne avec le marché. Pour **Fulham vs Burnley**, la victoire de Fulham est anticipée par le bookmaker ($C_H = 1.57$). Le score de sentiment (0.22) valide ce statut de favori. Le modèle déclenche le pari et l'emporte, agissant comme un filtre de confirmation.

5.5.3 Limites actuelles : L'incapacité à anticiper la neutralisation (Le Match Nul)

L'étude des échecs (les décisions *BET* soldées par un match nul) révèle le même biais structurel que celui rencontré sur notre Random Forest pré-équilibrage : le modèle binaire (favorable/défavorable) peine à conceptualiser l'issue neutre.

- Sur **Brentford vs Wolverhampton**, l'écart de sentiment est flagrant (0.3 vs 0.0) en faveur d'un hyper-favori ($C_H = 1.58$).
- Sur **Bournemouth vs Manchester United**, United domine légèrement l'attention médiatique (0.23 vs 0.17).

Dans les deux cas, le modèle engage un pari, mais les matchs se terminent sur des scores de parité. Il est difficile sémantiquement de détecter un sentiment penchant vers le match nul dans un article.

5.5.4 Efficacité du filtre d'abstention (RAS)

Le choix d'un seuil de décision strict ($S \geq 0.20$) s'avère judicieux. Lors des rencontres **Leeds vs Brentford** ou **Crystal Palace vs West Ham**, aucun des clubs ne parvient à générer une inertie suffisante (< 0.15). L'algorithme se place en statut "RAS" (Rien à Signaler). Ces deux rencontres s'étant soldées par des matchs nuls, l'abstention du modèle a permis de préserver le capital.

Conclusion : Sur cet échantillon, la stratégie de sentiment présente un bilan positif. En filtrant le "bruit" (les matchs indécis), elle s'est positionnée sur 5 rencontres. Elle en remporte 3 (dont deux cotes à l'outsider de 3.19 et 3.63) et en perd 2. Cela souligne le potentiel de la Data Linguistique.

5.6 L'impact de la Fraction de Kelly

Afin de mesurer finement l'impact du coefficient de *money management* sur la croissance de la bankroll, nous avons soumis l'algorithme à un protocole de *Grid Search* en faisant varier la fraction de Kelly sur quatre niveaux distincts : 0.10, 0.25, 0.70 et 0.95.

Le Tableau 4 synthétise les performances obtenues pour la meilleure combinaison d'hyperparamètres du Random Forest ($n_{\text{est}} = 100$, $d_{\text{max}} = 5$, $S_c = 0.0$) selon la fraction appliquée, avec un capital de départ de 100 €.

TABLE 4 – Impact de la fraction de Kelly sur le rendement du modèle

Fraction de Kelly	Nb. Paris	ROI Global	Capital Final
0.10 (Prudent)	304	+7.46 %	119.36 €
0.25 (Standard)	304	+7.02 %	144.84 €
0.70 (Optimum)	304	+6.73 %	202.72 €
0.95 (Agressif)	304	+4.57 %	176.76 €

5.6.1 Le Paradoxe ROI / Capital Final

L'analyse de ces variations met en lumière une dynamique contre-intuitive : **la maximisation du Retour sur Investissement (ROI) ne coïncide pas avec la maximisation du profit absolu**. Trois phases distinctes se dessinent :

1. **La zone de sous-exposition** ($f \leq 0.25$) : À son niveau le plus restrictif (0.10), l'algorithme enregistre son ROI le plus élevé (+7.46 %). Cependant, la croissance absolue de la bankroll est bridée (119.36 €). Le modèle est ultra-prudent : les paris sont très qualitatifs, mais les mises unitaires sont trop faibles pour activer réellement la puissance des intérêts composés.
2. **L'optimum d'efficience** ($f = 0.70$) : Lorsque la fraction est ajustée à 0.70, le capital final atteint son apogée à **202.72 €** (soit le double de la bankroll), alors même que le ROI baisse légèrement à +6.73 %. Ce point de convergence représente un bon compromis : le volume des mises est suffisamment agressif pour faire grossir le portefeuille, tout en maintenant un filet de sécurité face à la variance.
3. **La zone de sur-pari ou Overbetting** ($f = 0.95$) : En approchant du Kelly pur (0.95), les performances baissent mais Le ROI reste positif à +4.57 % ainsi que le capital 176.76 €. En engageant des sommes trop importantes sur chaque match, le modèle augmente sa volatilité. Les pertes inévitables lors des "séries noires" creusent des trous dans le capital.

5.7 Analyse de la Stratégie Value Betting (Anomalie de Forme)

Cette section analyse les performances d'une stratégie de *Value Betting* ciblant les anomalies de forme. L'approche repose sur l'hypothèse qu'un écart de forme significatif (calculé sur les 5 derniers matches) entre deux équipes peut mettre en évidence des cotes mal ajustées par les bookmakers. Nous avons simulé différentes configurations en croisant un **Seuil d'Écart de Forme** (la différence minimale de points sur 15 possibles) et une **Cote Minimale acceptée**.

5.7.1 Stratégies à Faible Écart de Forme (Seuil = 3 points)

Un seuil d'écart de 3 points représente une différence de dynamique légère à modérée entre les deux équipes.

- **Cote Haute (Seuil : 3, Cote Min : 1.8)** : Cette configuration génère un volume important d'opportunités (482 paris). Malgré un taux de réussite modeste de 38.80 %,

la stratégie parvient à dégager un ROI positif de **+3.25 %**, menant le capital final à 115.68 €. Bien que la courbe présente une volatilité marquée, l'exigence d'une cote minimale de 1.8 assure que les gains compensent structurellement le volume de pertes.

- **Cote Basse (Seuil : 3, Cote Min : 1.2)** : En abaissant drastiquement la cote minimale, le volume d'opportunités explose (865 paris). Le taux de réussite augmente mécaniquement à 50.52 %. Cependant, cette abondance est trompeuse. Le ROI devient négatif (-0.63 %), et le capital final tombe à 94.54 €. Accepter des cotes trop faibles (< 1.8) sur des écarts de forme marginaux ne permet pas de couvrir la marge du bookmaker sur le long terme.

5.7.2 Stratégies à Fort Écart de Forme (Seuil = 8 points)

Un seuil de 8 points traduit une asymétrie de forme sévère (par exemple, une équipe enchaînant les victoires face à une équipe en pleine crise). L'intuition voudrait que ces matchs offrent les meilleures garanties, mais la réalité mathématique est différente.

- **Cote Haute (Seuil : 8, Cote Min : 1.9)** : L'exigence combinée d'un écart de forme massif et d'une cote élevée réduit drastiquement le nombre d'opportunités (seulement 53 paris identifiés). Le taux de réussite s'effondre à 35.85 %, conduisant à un ROI lourdement négatif de **-16.55 %** (Capital final : 91.23 €). Ce résultat illustre un phénomène de marché connu : les bookmakers ajustent très agressivement les cotes lorsqu'un écart de forme est évident pour le grand public. Les rares cas où la cote reste élevée (≥ 1.9) malgré la forme cachent souvent des variables non statistiques (blessures majeures de dernière minute, enjeux biaisés en fin de saison), rendant le pari très risqué.
- **Cote Basse (Seuil : 8, Cote Min : 1.4)** : En acceptant des cotes plus basses, le volume remonte (130 paris) et le taux de réussite s'améliore (48.46 %). Néanmoins, le ROI reste profondément négatif (-12.92 %) pour un capital final de 83.21 €. Parier sur des "ultra-favoris" au vu de la forme n'est pas rentable. L'*overround* (la marge du bookmaker) est structurellement conçu pour pénaliser les parieurs qui suivent aveuglément les dynamiques évidentes.

5.7.3 Conclusion sur l'Anomalie de Forme

Les simulations démontrent que chercher l'évidence absolue (des écarts de forme massifs de 8 points) est économiquement destructeur. Les marchés sont efficients et intègrent très rapidement ces informations publiques dans les cotes.

À l'inverse, la seule configuration rentable s'est avérée être celle exploitant des **écarts de forme modérés (3 points) associés à des cotes intéressantes (≥ 1.8)**. Ce profil capte des asymétries plus subtiles que le marché sous-évalue occasionnellement, confirmant que le *Value Betting* réside dans l'exploitation de légers décalages plutôt que dans la poursuite des grandes certitudes.

6 Architecture Technique et Interface

L'application a été développée en langage Python, en utilisant la bibliothèque graphique standard `tkinter` pour l'interface utilisateur et `matplotlib` pour la visualisation des données. L'architecture repose sur une classe principale `ApplicationParis` qui orchestre les interactions entre le gestionnaire de données (`DataManager`) et les différents modules d'affichage.

6.1 Conception de l'Interface Graphique (GUI)

L'interface adopte un design moderne ("Dark Mode") défini par une palette de couleurs personnalisée (*Slate & Indigo*) pour optimiser le confort visuel lors de l'analyse de données

complexes. La navigation est structurée autour d'un widget `ttk.Notebook` divisant l'application en trois onglets fonctionnels distincts.

6.2 Module 1 : Simulation des Stratégies

Ce premier module (méthode `creer_interface_simulation`) est l'espace de backtesting. Il interagit directement avec les scripts heuristiques importés (`heuristic_homeAwayDraw`, `heuristic_risk`, `heuristic_custom`).

- **Configuration** : L'utilisateur définit son capital initial et sa mise unitaire.
- **Sélecteur de Stratégie** : Des boutons radio permettent de basculer entre les algorithmes (ex : *Low-Risk*, *Custom 3.0-4.0*).
- **Visualisation** : Un graphique `matplotlib` intégré via `FigureCanvasTkAgg` trace l'évolution de la bankroll en temps réel après chaque simulation, tandis qu'un panneau latéral résume les métriques clés (ROI, Taux de victoire).

Une capture d'écran illustrant ce module est disponible ici : **Figure 3**.

6.3 Module 2 : Programme et Suivi des Cotes

Nous avons commencé par implémenter un scraper pour récupérer les tweets et spéculations utilisateurs avant les matchs afin d'obtenir l'opinion publique sur le déroulement d'un match. Cependant, cette méthode n'étant pas fiable (devoir se fier à des inconnus sur le web, filtrer les tweets automatisés et capter l'intention de dizaines de tweets), nous avons remplacé cela par les côtes de deux sites majeurs de paris sportifs (Betclick et Winnamax). Les cotes de ces derniers sont générées par les bookmakers des sites respectifs (donc beaucoup plus fiable).

Ce module est matérialisé par l'onglet *Cotes & Scores Impliqués*. Son objectif principal est de centraliser la récupération des cotes en temps réel, d'estimer mathématiquement la distribution des scores et de générer des recommandations de paris basées sur l'espérance mathématique calculée par un modèle pré-entraîné sur la stratégie gagnante.

6.3.1 Flux de Récupération des Données Live

Le système s'approvisionne en données de cotes en temps réel via des requêtes adressées à l'API externe *The Odds API*. Le processus suit un protocole strict de requêtage et de sécurisation de l'affichage :

- **Paramétrage de la requête** : L'appel cible spécifiquement la Premier League anglaise (`soccer_epl`) pour la région Europe (`eu`), sur le marché du résultat brut (`h2h` : *Home/Draw/Away*) avec un format de cotes décimales.
- **Extraction et Filtrage** : À la réception du flux JSON, le module filtre et extrait prioritairement les cotes associées aux bookmakers agréés *Winnamax* (`winamax_fr`) et *Betclick* (`betclick_fr`). Pour chaque événement, les trois issues (*H*, *D*, *A*) sont isolées.
- **Mécanisme de secours (Fallback)** : Si l'API renvoie une liste vide (période de trêve ou hors-saison) ou si une erreur réseau survient, le programme bascule automatiquement sur un mode de démonstration injectant un jeu de données de 20 matchs simulés. Cela garantit la continuité opérationnelle de l'interface graphique.

6.3.2 Traitement des Données et Inférence par l'IA

Une fois les données brutes extraites, elles sont immédiatement soumises à un pipeline de traitement avant d'être injectées dans le modèle pré-entraîné **Random Forest**.

1. **Normalisation syntaxique** : Les noms d'équipes provenant de l'API (ex : "*Manchester United*") subissent un alignement textuel via un dictionnaire de correspondance pour correspondre exactement à la nomenclature historique du modèle (ex : "*Man United*").
2. **Encodage numérique** : Les chaînes textuelles normalisées des équipes domicile (*Home*) et extérieur (*Away*) sont converties en valeurs numériques discrètes à l'aide d'un encodeur de labels (`LabelEncoder`) préalablement entraîné :

$$\text{code}_H = \text{transform}(\text{Home}), \quad \text{code}_A = \text{transform}(\text{Away})$$

3. **Construction du vecteur d'entrée** : Les variables sont encapsulées dans un objet `DataFrame` standardisé, calqué sur les caractéristiques d'entraînement (*features*) :

$$X_{\text{live}} = [\text{code}_H \quad \text{code}_A \quad O_H \quad O_D \quad O_A]$$

Où O_H , O_D , et O_A représentent les cotes décimales extraites.

4. **Inférence et Stratégie Custom (Away Strategy)** : Le modèle Random Forest exécute la méthode `predict_proba(X_live)` pour retourner les probabilités associées aux trois issues. Le système isole la probabilité de victoire à l'extérieur $P(A)$ et applique une règle métier stricte pour valider l'Espérance Mathématique (EV) du signal :

Algorithm 1: Logique de décision et filtrage de la stratégie custom

Input: Cote extérieure O_A , Probabilité prédite $P(A)$

Output: Statut de la recommandation

if $3.0 \leq O_A \leq 4.0$ **then**

$EV \leftarrow P(A) \times O_A$

if $EV \geq 1.05$ **then**

return "*BET Extérieur (Prise de position)*"

else

return "*Non rentable*"

return "*Cote hors limites*"

Une capture d'écran illustrant ce module est disponible ici : **Figure 4**.

6.4 Module 3 : Random Forest et Grid Search

Ce module présente un espace de contrôle dédié à l'expérimentation du Random Forest permettant à l'utilisateur d'utiliser le modèle selon deux modes opératoires distincts, commutables via des boutons radio.

6.4.1 Le Mode "Simulation Simple"

Ce mode est conçu pour évaluer instantanément la viabilité d'une configuration d'hyperparamètres unique. L'utilisateur a la possibilité de :

- **Moduler la politique d'investissement** : Ajuster dynamiquement le capital de départ ainsi que le montant de la mise unitaire allouée à chaque rencontre.
- **Paramétrer l'architecture du RF** : Définir le nombre d'arbres de décision (`n_estimators`), la profondeur maximale de l'apprentissage (`max_depth`) pour contrôler le sur-apprentissage, et fixer le germe aléatoire (`random_state`) pour garantir la reproductibilité de l'expérience.
- **Activer le filtre** : Ajuster le `seuil_confiance` (S_c) afin d'interdire au modèle de parier sur les rencontres dont l'incertitude dépasse la limite tolérée.
- **Interpréter les résultats visuels** : Un graphique représentant la courbe de l'évolution du capital au fil de la saison.

Une capture d'écran illustrant ce module est disponible ici : **Figure 5**.

6.4.2 Le Mode "Grid Search"

Ce mode bascule l'application vers un protocole de recherche visant à identifier la combinaison optimale. L'utilisateur peut :

- **Saisir des grilles de variables** : Injecter des listes d'hyperparamètres au sein des champs de saisie en utilisant un séparateur (virgule), permettant de tester simultanément plusieurs configurations.
- **Superviser l'apprentissage en direct** : Suivre le déroulement séquentiel des simulations via une console intégrée. Cette console affiche en temps réel l'indice de progression et le verdict financier de chaque itération sans jamais figer l'interface.
- **Consulter le palmarès des modèles** : À l'échéance du calcul, l'interface extrait et affiche directement dans la console un résumé du **Top 10 des meilleures combinaisons** d'hyperparamètres, triées par ordre de rentabilité décroissant.
- **Archiver l'historique complet** : L'intégralité des données de l'espace exploré (incluant les configurations en perte) est automatiquement exportée dans un fichier structuré (`resultats_grid_search_interface.csv`).

Une capture d'écran illustrant ce module est disponible ici : **Figure 6**.

6.5 Module 4 : Prédictions via Analyse de Sentiment

Le troisième onglet, implémenté dans la méthode `creer_interface_predictions`, intègre une dimension prédictive avancée basée sur l'analyse de l'actualité (News & Sentiment).

- **Pipeline de Prédiction** : L'utilisateur peut lancer la génération de prédictions pour une échéance donnée (ex : J+1). Cette opération, coûteuse en temps de calcul, est exécutée dans un *Thread* séparé pour ne pas figer l'interface graphique.
- **Intégration CSV** : Le système permet de charger des fichiers de résultats générés par le script `matches_data_dayafter`.
- **Restitution** : Un tableau dédié affiche pour chaque match les scores de sentiment (Sent. Home / Sent. Away) et la décision finale suggérée par l'algorithme, offrant ainsi une aide à la décision complémentaire aux heuristiques purement statistiques.

Une capture d'écran illustrant ce module est disponible ici : **Figure 7**.

6.6 Module 5 : Forme et Prédiction IA

Ce module a été conçu pour offrir à l'utilisateur une double perspective : une vision de l'état de forme récent des équipes (le tableau de bord) et une vision unitaire via un simulateur de confrontation directe.

6.6.1 Le Tableau de Bord de Forme

La moitié supérieure de l'interface est occupée par un tableau de données qui agrège les indicateurs de performance clés calculés exclusivement sur les cinq dernières rencontres de chaque équipe. Cet outil intègre les variables suivantes du jeu de données :

- **Le bilan classique** : Volume de points ($Pts = 3*V + 1*N$), victoires (V), nuls (N) et défaites (D).
- **La balance offensive et défensive** : Buts marqués (Buts+), buts encaissés (Buts-) et la différence de buts différentielle (Diff).
- **Autres statistiques** : Le volume cumulé de tirs tentés, l'indicateur de domination territoriale mesuré par les tirs cadrés, ainsi que l'agressivité ou la désorganisation quantifiée par le nombre de fautes commises.

Ce tableau permet à l'analyste d'identifier en un coup d'œil les équipes sous-évaluées ou en surchauffe statistique avant de placer un pari.

6.6.2 Le Simulateur de Confrontation Directe

La moitié inférieure permet la prédiction unitaire. L'utilisateur peut simuler le dénouement d'une affiche hypothétique ou réelle de son choix en configurant lui-même les variables du marché :

- **Sélection des opposants** : Deux menus déroulants permettent de définir l'équipe à domicile et l'équipe à l'extérieur.
- **Saisie de l'indice des cotes** : L'utilisateur renseigne les trois cotes du marché (C_{Home} , C_{Draw} , C_{Away}). Cette étape est mathématiquement obligatoire car le modèle prédictif utilise l'évaluation du bookmaker comme une variable explicative majeure condensant l'état du contexte (blessures, enjeux).
- **Interrogation du modèle** : Lors du clic sur le bouton d'action, l'entraînement de l'algorithme *Random Forest* démarre sur l'intégralité de la base historique.
- **Verdict de probabilités** : L'interface affiche sous forme de pourcentages colorés le vecteur complet des probabilités a posteriori de l'événement (Victoire Domicile, Match Nul, Victoire Extérieur).

Une capture d'écran illustrant ce module est disponible ici : **Figure 8**.

7 Répartition du Travail

Le tableau ci-dessous synthétise la contribution principale de chaque étudiant :

Membre	Responsabilités et Tâches Principales
LAWIN DIRIK	Information : stats_forme.py Machine Learning : Développement du modèle <i>Random Forest</i> (random_forest.py), du grid_search_RF.py (sans kelly) ainsi que stats_h2h.py et evaluationRF.py Interface : Conception des onglets "Simulation Stratégie", "Random Forest & Grid Search" ainsi que "Forme & Prédiction IA".
FANTIN VICO	Data Engineering & Web Scraping : Pipeline de collecte via APIs et scraping du contenu textuel intégral des articles de presse (data_load_source.py, articlev2_scrapper.py via newspaper3k). Traitement du Langage Naturel (NLP) & Analyse Contextuelle : Développement de la stratégie de prédiction médiatique (analyse_article.py). Value Betting : Utilisation de l'analyse de forme et d'un filtre de côte minimale pour parier. Interface : Conception et intégration de l'onglet "Value Betting et amélioration de l'onglet RF et Grid Search".
CLÉMENT BOLIFRAUD	Interface : Conception de l'onglet "Côtes & scores impliqués" Optimisation de la stratégie gagnante : Implémentation du modèle RandomForest à notre stratégie custom. Flux de Données : Récupération et structuration en temps réel des données de matchs et cotes depuis des sites de paris pour l'affichage interactif et émission de prédictions du modèle .
<i>Commun</i>	Stratégies Heuristiques et Simulation : Implémentation de backtesting, développement des algorithmes <i>Low/High Risk</i> et de la stratégie <i>Custom</i> . Calcul des métriques (ROI, Win Rate). Rapport et Diapo pour la soutenance.

TABLE 5 – Répartition des tâches au sein du groupe

8 Conclusion et Perspectives

Au terme de ce projet, nous avons réussi à développer une chaîne de traitement complète, allant de l'acquisition de données brutes à la prise de décision algorithmique via une interface graphique fonctionnelle.

L'analyse des résultats permet de tirer trois conclusions majeures :

- **La sélectivité contre l'efficience du marché** : L'échec systématique des stratégies naïves et la neutralité financière du *Random Forest* de base ($ROI = 0.16\%$) confirment la forte efficience des cotes proposées par les bookmakers. L'algorithme natif, en cherchant à maximiser son exactitude globale, adopte un comportement prudent axé sur les favoris à faible cote dont le rendement est structurellement absorbé par l'*overround*. La rentabilité n'a pu être atteinte qu'à travers la spécialisation : notre stratégie *Custom* isolant les cotes extérieures intermédiaires ($3.0 \leq C_A < 4.0$) a validé l'existence d'asymétries locales, combiné au *Random Forest* qui propulse le ROI à **+11.08%**.
- **Le coût financier de l'équilibre mathématique** : L'évaluation de la repondération des classes via le paramètre `class_weight="balanced"` nous montre que : si l'ajuste-

ment résout le biais de la classe majoritaire en forçant la prédiction de matchs nuls, il s'avère économiquement destructeur en multipliant les faux positifs. Le biais initial de l'IA, consistant à ignorer le nul, représente en réalité une stratégie de préservation du capital.

- **L'importance du *Money Management*** : Les simulations basées sur le critère de Kelly ont démontré que la performance d'un système de trading sportif dépend tout autant de la gestion des tailles de positions que de la précision des prédictions. L'optimisation de la fraction de Kelly à 0.70 a permis d'exploiter la dynamique des intérêts composés pour doubler la *bankroll* initiale (**202.72 €**), confirmant que l'ajustement des mises en fonction de l'espérance mathématique est le pilier de la rentabilité à long terme.

Pour prolonger ces travaux et tenter d'augmenter significativement la rentabilité, plusieurs pistes d'évolution ont été identifiées :

- **Enrichissement des données** : L'intégration de statistiques individuelles (blessures de joueurs clés, compositions probables ...) permettrait d'affiner la précision du modèle au-delà des simples données historiques de match.
- **Exploration du Deep Learning** : L'utilisation de réseaux de neurones profonds pourrait permettre de capturer des relations non-linéaires encore plus complexes que le Random Forest, à condition d'avoir suffisamment de données.

En conclusion, bien que battre les teneurs de marché reste un défi mathématique ardu, ce projet démontre qu'en associant algorithmique de sélection, modélisation probabiliste rigoureuse et une gestion de portefeuille fractionnaire, il est tout à fait possible de neutraliser l'avantage du bookmaker et de dégager des profits réels et systématiques sur des segments de marché ciblés.

Il convient de préciser que plusieurs algorithmes de Machine Learning ont été initialement mis à l'essai lors des premières phases du projet. Toutefois, face à des performances initiales peu convaincantes sur les données de test, nous avons préféré focaliser l'intégralité de nos travaux et de nos phases d'optimisation sur le modèle Random Forest.

A Annexes : Visuels de l'Interface




FIGURE 1 – Matrice de Confusion RF




FIGURE 2 – Matrice de Confusion RF Balanced




FIGURE 3 – Interface du Module 1 : Simulation et Backtesting



FIGURE 4 – Interface du Module 2 : Matches à venir, cotes et prédictions




FIGURE 5 – Interface du Module 3 : Mode Simulation Simple du RF




FIGURE 6 – Interface du Module 3 : Mode Grid Search du RF




FIGURE 7 – Interface du Module 4 : Prédictions via Analyse de Sentiment

État de Forme (5 derniers matchs)											
Équipe	Pts	V	N	D	Buts+	Buts-	Diff	Tirs	Tirs Cadrés	Fautes	
Nott'm Forest	6	2	0	3	7	9	-2	69	19	41	
Fulham	5	1	2	2	6	10	-4	52	18	51	
Leicester	5	1	2	2	7	11	-4	51	24	49	
Aston Villa	5	1	2	2	8	12	-4	52	16	50	
Burnley	4	1	1	3	8	10	-2	76	27	53	
Brighton	4	1	1	3	3	8	-5	72	18	62	
West Ham	4	1	1	3	8	16	-8	55	21	48	
Wolves	3	1	0	4	4	12	-8	47	20	65	
West Brom	1	0	1	4	5	12	-7	60	17	53	
Southampton	1	0	1	4	9	16	-7	48	20	50	
Watford	1	0	1	4	3	10	-7	46	10	49	
Leeds	1	0	1	4	6	15	-9	39	17	64	

Prédiction IA (Random Forest)											
Domicile :	Arsenal	Extérieur :	Chelsea								
Cote Domicile :	3.75	Cote Nul :	3.85	Cote Extérieur :	4.1	PRÉDIRE LE MATCH					
Victoire Arsenal : 59.41%				Match Nul : 23.91%				Victoire Chelsea : 16.69%			

FIGURE 8 – Interface du Module 5 : Forme et Prédiction par RF